

Análise de Tendências na Plataforma TabNews: Relatório Técnico de Mineração de Texto Temporal

Lucas Henrique Valentim Rocha

Junho de 2026

1 Introdução

Neste relatório, eu descrevo o processo de mineração de texto temporal que executei sobre o *dataset* da plataforma TabNews, integrando esta etapa ao pipeline de Descoberta de Conhecimento em Bancos de Dados (KDD). O objetivo central deste trabalho consistiu em mapear a evolução dos interesses técnicos da comunidade ao longo do tempo. Como o TabNews atrai uma base de usuários altamente focada em desenvolvimento de software e tecnologia, eu busquei identificar como os tópicos emergentes ganham tração e como as discussões estruturais se mantêm estáveis ao longo de uma janela temporal que se estende de maio de 2022 a junho de 2026. Este documento reconstrói as decisões metodológicas que tomei, apresenta as visualizações obtidas e discute a relevância desses padrões para o entendimento da dinâmica de redes de conhecimento técnico.

2 Metodologia e Pré-processamento

Para extrair o comportamento temporal oculto nos textos, eu utilizei a base transformada do KDD, unificando o título e o corpo de cada publicação em uma única variável textual. O maior desafio desta etapa residiu na eliminação do ruído estrutural inerente a fóruns de programação. Eu desenvolvi e apliquei funções personalizadas baseadas em expressões regulares para remover blocos de código Markdown delimitados por crases triplas, tags HTML e entidades de escape de texto. Além disso, eu filtrei o *corpus* eliminando caracteres especiais, numerais e pontuações, convertendo todos os termos para letras minúsculas.

Na filtragem de palavras de baixo valor semântico, eu adotei a lista de *stopwords* em português da biblioteca NLTK e a expandi manualmente com termos estruturais comuns que poluíam os tópicos, tais como termos de formatação web e palavras reservadas de linguagens de programação. Após a limpeza, eu agrupei as strings resultantes de forma cronológica, consolidando o texto inteiro de cada mês em um único documento macro. Esta modelagem transformou o problema de análise de múltiplos *posts* individuais em um problema clássico de mineração de texto sobre uma coleção temporal de documentos indexados por meses.

3 Análise e Discussão dos Resultados

Eu utilizei duas frentes analíticas complementares para examinar os dados processados: o modelo estatístico TF-IDF (*Term Frequency-Inverse Document Frequency*) para detectar a singularidade de cada período, e o cálculo de frequência relativa bruta para monitorar a intensidade absoluta de termos específicos.

3.1 Extração de Singularidades Mensais com TF-IDF

Eu configurei o vetorizador TF-IDF com o parâmetro de frequência máxima de documento em 0,85. Essa restrição matemática garantiu que qualquer palavra presente em mais de 85% dos meses fosse descartada do cálculo de relevância. Eu tomei essa decisão para forçar o algoritmo a ignorar os termos cotidianos da rede e destacar apenas os picos isolados de novidade. O resultado dessa abordagem gerou o arquivo `tabela_top_termos_mensais.csv`. Eu sumariei uma amostra significativa dessa série temporal na Tabela 1 para ilustrar os marcos evolutivos descobertos pelo algoritmo.

Tabela 1: Amostra Cronológica dos Top Termos Extraídos via TF-IDF

Período (Mês-Ano)	Termos de Maior Relevância (TF-IDF)
2022-05	axios, milestone, heroku, paginação, webhook
2022-08	dall, diffusion, stable, username, unity
2023-01	bitcoin, computer, dataframe, science, carros
2023-06	descricao, axios, matriz, scrum, dockerfile
2024-02	zed, fevereiro, debatido, hub, elixir
2024-10	wsl, matriz, table, embeddings, estruturados
2025-02	orquestrador, acoplamento, saga, deepseek, microserviços
2025-10	cron, llm, gemini, claude, llms
2026-04	claude, mcp, agente, llm, anthropic

Ao analisar o arquivo `tabela_top_termos_mensais.csv`, eu observei que o TF-IDF capturou com precisão a cronologia das inovações globais de tecnologia. No início do ciclo (2022), a comunidade focava em tópicos de infraestrutura e arquitetura tradicional de desenvolvimento web. Entre agosto e outubro de 2022, o algoritmo isolou o surgimento abrupto da inteligência artificial generativa de imagens através dos termos *dall*, *diffusion* e *stable*. No início de 2023, o interesse oscilou temporariamente em direção ao ecossistema de criptoativos (*bitcoin*). O marco final da série histórica, observado entre o final de 2025 e o primeiro semestre de 2026, documenta a dominância massiva e contínua dos modelos de linguagem e arquiteturas baseadas em agentes (*claude*, *mcp*, *agente*, *llm*). Eu interpreto que esse resultado evidencia uma rede social altamente sintonizada com as tendências de mercado, comportando-se como um termômetro em tempo real de adoção tecnológica.

3.2 Visualização de Trajetórias Temporais

Para avaliar o ciclo de vida dessas tendências, eu selecionei quatro palavras-chave representativas das transições identificadas e plotei suas frequências relativas normalizadas por dez mil palavras. O gráfico de linhas resultante eu apresento e analiso na Figura 1.




Figura 1: Evolução Temporal e Ciclo de Vida de Termos Selecionados

O exame detalhado da Figura 1 confirma visualmente a natureza cíclica dos interesses da comunidade. O termo *diffusion* exibe um pico agudo e isolado no final de 2022, desaparecendo quase por completo nos anos seguintes, o que caracteriza um comportamento típico de *hype* tecnológico concentrado. O termo *bitcoin* apresenta oscilações periódicas menores com um teto claro de engajamento. Em contrapartida, as trajetórias de *claude* e *agente* mostram um comportamento radicalmente distinto a partir de 2025: elas quebram o padrão de picos isolados e sustentam uma rampa de aceleração contínua até os limites de 2026. Isso me indica que a inteligência artificial textual e a autonomia de software deixaram de ser interesses passageiros e se converteram no paradigma central de discussão da comunidade.

3.3 O Paradoxo dos Termos Estruturais: Análise do Mapa de Calor

Durante o desenvolvimento do projeto, eu notei que linguagens de programação populares como Python, React e Rust não figuravam na lista de principais termos do arquivo CSV estruturado pelo TF-IDF. Para investigar se esses assuntos estavam ausentes da rede ou se a penalização matemática os havia omitido, eu construí uma matriz expandida de termos utilizando a frequência relativa bruta e gerei a visualização em mapa de calor exibida na Figura 2.

A leitura da Figura 2 resolveu o paradoxo analítico e validou a solidez da minha abordagem metodológica. No mapa de calor, as linhas correspondentes a *Python*, *React* e *Rust* mantêm uma coloração escura e homogênea ao longo de quase toda a linha do tempo. Isso comprova que essas ferramentas são discutidas de maneira constante e volumosa em todos os períodos.

Esse fenômeno justifica por que elas foram descartadas pelo TF-IDF: por estarem presentes em praticamente 100% dos meses, o peso do IDF zerou a sua importância local. Eu concluo que o TabNews possui duas camadas discursivas paralelas: uma infraestrutura estável de tópicos de engenharia de software (mapeada no calor contínuo do *heatmap*) e uma superestrutura de ondas de inovação voláteis (mapeada nas linhas de tendência e no isolamento do TF-IDF).




Figura 2: Mapa de Calor de Intensidade de Assuntos e Termos Estruturais

4 Conclusão

Ao final da análise, concluo que a mineração de texto temporal aplicada ao *dataset* do TabNews foi capaz de revelar não apenas quais tecnologias foram discutidas pela comunidade, mas principalmente como esses interesses se transformaram ao longo do tempo. A combinação entre TF-IDF e frequência relativa mostrou-se essencial para separar dois comportamentos distintos: de um lado, os temas estruturais e recorrentes, como linguagens e ferramentas consolidadas de desenvolvimento; de outro, os movimentos de inovação que surgem em ciclos mais curtos, ganham destaque em determinados períodos e, em alguns casos, passam a ocupar uma posição central nas discussões.

Os resultados indicam que o TabNews funciona como um espaço sensível às mudanças do ecossistema tecnológico. Tendências como inteligência artificial generativa, modelos de linguagem, agentes autônomos e ferramentas associadas aparecem na série temporal de forma coerente com sua expansão no debate técnico mais amplo. Ao mesmo tempo, a permanência de termos como *Python*, *React* e *Rust* demonstra que a comunidade não abandona sua base prática de engenharia de software, mas incorpora novas camadas de discussão sobre essa fundação já estabelecida.

Dessa forma, o estudo confirma a utilidade do processo de KDD para transformar um grande volume de publicações textuais em conhecimento interpretável sobre a dinâmica de uma comunidade técnica. Mais do que produzir rankings de palavras, a análise permitiu compreender a relação entre estabilidade e mudança no comportamento discursivo dos usuários. Assim, este trabalho evidencia que a observação temporal de textos em plataformas colaborativas pode servir como um instrumento relevante para acompanhar a adoção, a consolidação e a substituição de tendências tecnológicas dentro de redes de conhecimento.